Segundo avance — StoryTrack

Estructuración y limpieza de subtítulos

Dylan Madrigal Jiménez C5G687
María José Angulo Salas C5C507
Gabriel Guevara Cornejo C5F689
Harol Arias Sánchez C5J614

1 Procesamiento de los subtítulos

Los datos originales corresponden a archivos de subtítulos en formato ".srt". Para estructurar la información se creó la función "leer.subtitulos()", la cual identifica cada bloque de subtítulos y extrae las variables necesarias para construir la base de datos.

```
leer.subtitulos <- function(ruta.archivo) {
  lineas <- readLines (ruta.archivo, encoding = "UTF-8")
  separadores <- which(lineas== "")
  bordes <- c(0, separadores, length(lineas)+1)
  subtitulos <- data.frame() #Se crea subtitulos como un data.frame vacio
  nombre.archivo <- basename(ruta.archivo)
  temporada <- regmatches(nombre.archivo, regexpr("S[0-9]{2}", nombre.archivo))
  episodio <- regmatches(nombre.archivo, regexpr("E[0-9]{2}", nombre.archivo))
  temporada <- as.integer(substr(temporada, 2, 3)) #Se extrae el dato númerico
  episodio <- as.integer(substr(episodio, 2, 3)) #Igual que el anterior
  serie <- sub(" S[0-9]{2}E[0-9]{2}.*", "", nombre.archivo)
  for (i in 1: (length(bordes)-1)){ #Se encarga de recorrer bloque por bloque extrayendo las variables requeridas
    bloque.actual <- lineas[(bordes[i]+1):(bordes[i+1]-1)] #Todos los bloques mantienen el mismo formato
    numero.bloque <- as.integer(bloque.actual[1])
    tiempo <- bloque.actual[2]
    tiempos <- strsplit(tiempo, " --> ")[[1]]
    inicio.sub <- tiempos[1]
    fin.sub <- tiempos[2]
```

```
    texto.sub <- paste(bloque.actual[3:length(bloque.actual)], collapse = " ") #Paste une los textos separados
    fila.sub <- data.frame( #Se almacenan los datos en una variable
      serie = serie,
      temporada = temporada,
      episodio = episodio,
      bloque = numero.bloque,
      inicio = inicio.sub,
      fin = fin.sub,
      texto = texto.sub,
      archivo = nombre.archivo
    )
    subtitulos <- rbind(subtitulos, fila.sub) #Usamos rbind para añadir las filas resultantes al dataframe original
  }
  subtitulos
}
```

2 Consolidación de los episodios

Los archivos ".srt" disponibles se identificaron automáticamente y se procesaron con la función anterior. Posteriormente, las tablas correspondientes a cada episodio se unieron en una sola base de datos.

```
archivos.srt <-  list.files(path = here::here("data", "SubtitulosOriginales"), pattern = "\\.srt$", full.names = TRUE)
subtitulos.consolidados <- data.frame()
for (ruta in archivos.srt) {
  datos.archivo <- leer.subtitulos(ruta)
  subtitulos.consolidados <- rbind(subtitulos.consolidados, datos.archivo)
}
```

3 Revisión y limpieza de los datos

Se revisó la base consolidada para identificar valores faltantes, campos vacíos y registros duplicados.

```
colSums(is.na(subtitulos.consolidados))
```

```
    serie temporada  episodio    bloque    inicio       fin     texto   archivo 
        0         0         0         0         0         0         0         0 
```

```r
colSums(subtitulos.consolidados == "")
```

```
    serie temporada  episodio    bloque    inicio       fin     texto   archivo
        0         0         0         0         0         0         0         0
```

```r
sum(duplicated(subtitulos.consolidados))
```

```
[1] 0
```

4 Variables de la base

La base final contiene ocho variables:

- `serie`: nombre de la serie.
- `temporada`: número de temporada.
- `episodio`: número de episodio.
- `bloque`: número del bloque de subtítulo.
- `inicio`: tiempo de inicio del subtítulo.
- `fin`: tiempo de finalización del subtítulo.
- `texto`: contenido textual del subtítulo.
- `archivo`: archivo `.srt` de origen.

5 Base de datos consolidada

A continuación se presentan las primeras 10 observaciones de la base de datos consolidada.

```r
tabla.final <- head(subtitulos.consolidados, 10)

tinytable::tt(
  tabla.final,
  caption = "Primeras 10 filas de la base de subtítulos consolidada",
  theme = "striped",
  escape = TRUE,
  width = 0.95
) |>
```

```
tinytable::style_tt(
  fontsize = 0.8
)
```

Table 1: Primeras 10 filas de la base de subtítulos consolidada

serie	temporada	episodio	bloque	inicio	fin	texto	archivo
The Big Bang Theory	1	2	1	00:00:02,958	00:00:05,169	Aquí tienes. Comida tailandesa sin maní.	The Big Bang Theory S01E02 The Big Bran Hypothesis (1080p x265 10bit Joy).es.srt
The Big Bang Theory	1	2	2	00:00:05,336	00:00:06,587	? Y tiene aceite de maní?	The Big Bang Theory S01E02 The Big Bran Hypothesis (1080p x265 10bit Joy).es.srt
The Big Bang Theory	1	2	3	00:00:06,754	00:00:07,797	No lo sé.	The Big Bang Theory S01E02 The Big Bran Hypothesis (1080p x265 10bit Joy).es.srt
The Big Bang Theory	1	2	4	00:00:07,963	00:00:11,926	Todos vigilen a Howard por si se inflama.	The Big Bang Theory S01E02 The Big Bran Hypothesis (1080p x265 10bit Joy).es.srt
The Big Bang Theory	1	2	5	00:00:12,093	00:00:15,262	No hay abejas ahora, así que toma mi epinefrina.	The Big Bang Theory S01E02 The Big Bran Hypothesis (1080p x265 10bit Joy).es.srt
The Big Bang Theory	1	2	6	00:00:15,805	00:00:18,516	- ?No tienen palitos? - No necesitas palitos, es comida tailandesa.	The Big Bang Theory S01E02 The Big Bran Hypothesis (1080p x265 10bit Joy).es.srt
The Big Bang Theory	1	2	7	00:00:18,683	00:00:20,017	Santo Dios.	The Big Bang Theory S01E02 The Big Bran Hypothesis (1080p x265 10bit Joy).es.srt
The Big Bang Theory	1	2	8	00:00:20,184	00:00:23,312	En Tailandia usan tenedor desde la segunda mitad del siglo XIX.	The Big Bang Theory S01E02 The Big Bran Hypothesis (1080p x265 10bit Joy).es.srt
The Big Bang Theory	1	2	9	00:00:23,479	00:00:27,233	No se ponen el tenedor en la boca.	The Big Bang Theory S01E02 The