Segundo avance — StoryTrack

Estructuración y limpieza de subtítulos

Dylan Madrigal Jiménez C5G687
María José Angulo Salas C5C507
Gabriel Guevara Cornejo C5F689
Harol Arias Sánchez C5J614

1 Procesamiento de los subtítulos

Los datos originales corresponden a archivos de subtítulos en formato ".srt". Para estructurar la información se creó la función "leer.subtitulos()", la cual identifica cada bloque de subtítulos y extrae las variables necesarias para construir la base de datos.

```
leer.subtitulos <- function(ruta.archivo) {
  lineas <- readLines (ruta.archivo, encoding = "UTF-8")
  separadores <- which(lineas== "")
  bordes <- c(0, separadores, length(lineas)+1)
  subtitulos <- data.frame() #Se crea subtitulos como un data.frame vacio
  nombre.archivo <- basename(ruta.archivo)
  temporada <- regmatches(nombre.archivo, regexpr("S[0-9]{2}", nombre.archivo))
  episodio <- regmatches(nombre.archivo, regexpr("E[0-9]{2}", nombre.archivo))
  temporada <- as.integer(substr(temporada, 2, 3)) #Se extrae el dato númerico
  episodio <- as.integer(substr(episodio, 2, 3)) #Igual que el anterior
  serie <- sub(" S[0-9]{2}E[0-9]{2}.*", "", nombre.archivo)
  for (i in 1: (length(bordes)-1)){ #Se encarga de recorrer bloque por bloque extrayendo las variables requeridas
    bloque.actual <- lineas[(bordes[i]+1):(bordes[i+1]-1)] #Todos los bloques mantienen el mismo formato
    numero.bloque <- as.integer(bloque.actual[1])
    tiempo <- bloque.actual[2]
    tiempos <- strsplit(tiempo, " --> ")[[1]]
    inicio.sub <- tiempos[1]
    fin.sub <- tiempos[2]
```

```
    texto.sub <- paste(bloque.actual[3:length(bloque.actual)], collapse = " ") #Paste une los textos separados
    fila.sub <- data.frame( #Se almacenan los datos en una variable
      serie = serie,
      temporada = temporada,
      episodio = episodio,
      bloque = numero.bloque,
      inicio = inicio.sub,
      fin = fin.sub,
      texto = texto.sub,
      archivo = nombre.archivo
    )
    subtitulos <- rbind(subtitulos, fila.sub) #Usamos rbind para añadir las filas resultantes al dataframe original
  }
  subtitulos
}
```

2 Consolidación de los episodios

Los archivos ".srt" disponibles se identificaron automáticamente y se procesaron con la función anterior. Posteriormente, las tablas correspondientes a cada episodio se unieron en una sola base de datos.

```
archivos.srt <-  list.files(path =  "data/SubtitulosOriginales", pattern = "\\.srt$", full.names = TRUE)
subtitulos.consolidados <- data.frame()
for (ruta in archivos.srt) {
  datos.archivo <- leer.subtitulos(ruta)
  subtitulos.consolidados <- rbind(subtitulos.consolidados, datos.archivo)
}
```

3 Revisión y limpieza de los datos

Se revisó la base consolidada para identificar valores faltantes, campos vacíos y registros duplicados.

```
colSums(is.na(subtitulos.consolidados))
```

```
    serie temporada  episodio    bloque    inicio       fin     texto   archivo 
        0         0         0         0         0         0         0         0 
```

```r
colSums(subtitulos.consolidados == "")
```

```
    serie temporada  episodio    bloque    inicio       fin     texto   archivo
        0         0         0         0         0         0         0         0
```

```r
sum(duplicated(subtitulos.consolidados))
```

```
[1] 0
```

4 Variables de la base

La base final contiene ocho variables:

- `serie`: nombre de la serie.
- `temporada`: número de temporada.
- `episodio`: número de episodio.
- `bloque`: número del bloque de subtítulo.
- `inicio`: tiempo de inicio del subtítulo.
- `fin`: tiempo de finalización del subtítulo.
- `texto`: contenido textual del subtítulo.
- `archivo`: archivo `.srt` de origen.

5 Base de datos consolidada

A continuación se presentan las primeras 10 observaciones de la base de datos consolidada.

Table 1: Primeras 10 filas de la base de subtítulos consolidada

serie	temporada	episodio	bloque	inicio	fin	texto	archivo
The Big Bang Theory	1	2	1	00:00:02,958	00:00:05,169	Aquí tienes. Comida tailandesa sin maní.	The Big Bang Theory S01E02 The Big Bran Hypothesis (1080p x265 10bit Joy).es.srt
The Big Bang Theory	1	2	2	00:00:05,336	00:00:06,587	? Y tiene aceite de maní?	The Big Bang Theory S01E02 The Big Bran Hypothesis (1080p x265 10bit Joy).es.srt
The Big Bang Theory	1	2	3	00:00:06,754	00:00:07,797	No lo sé.	The Big Bang Theory S01E02 The Big Bran Hypothesis (1080p x265 10bit Joy).es.srt
The Big Bang Theory	1	2	4	00:00:07,963	00:00:11,926	Todos vigilen a Howard por si se inflama.	The Big Bang Theory S01E02 The Big Bran Hypothesis (1080p x265 10bit Joy).es.srt
The Big Bang Theory	1	2	5	00:00:12,093	00:00:15,262	No hay abejas ahora, así que toma mi epinefrina.	The Big Bang Theory S01E02 The Big Bran Hypothesis (1080p x265 10bit Joy).es.srt
The Big Bang Theory	1	2	6	00:00:15,805	00:00:18,516	- ?No tienen palitos? - No necesitas palitos, es comida tailandesa.	The Big Bang Theory S01E02 The Big Bran Hypothesis (1080p x265 10bit Joy).es.srt
The Big Bang Theory	1	2	7	00:00:18,683	00:00:20,017	Santo Dios.	The Big Bang Theory S01E02 The Big Bran Hypothesis (1080p x265 10bit Joy).es.srt
The Big Bang Theory	1	2	8	00:00:20,184	00:00:23,312	En Tailandia usan tenedor desde la segunda mitad del siglo XIX.	The Big Bang Theory S01E02 The Big Bran Hypothesis (1080p x265 10bit Joy).es.srt
The Big Bang Theory	1	2	9	00:00:23,479	00:00:27,233	No se ponen el tenedor en la boca, lo usan para poner la comida en la cuchara...	The Big Bang Theory S01E02 The Big Bran Hypothesis (1080p x265 10bit Joy).es.srt
The Big Bang Theory	1	2	10	00:00:27,400	00:00:29,610	...y se la llevan a la boca.	The Big Bang Theory S01E02 The Big Bran Hypothesis (1080p x265 10bit Joy).es.srt