Segundo avance — StoryTrack

Estructuración y limpieza de subtítulos

Dylan Madrigal Jiménez C5G687
María José Angulo Salas C5C507
Gabriel Guevara Cornejo C5F689
Harol Arias Sánchez C5J614

1 Procesamiento de los subtítulos

Los datos originales corresponden a archivos de subtítulos en formato ".srt". Para estructurar la información se creó la función "leer.subtitulos()", la cual identifica cada bloque de subtítulos y extrae las variables necesarias para construir la base de datos.

2 Consolidación de los episodios

Los archivos ".srt" disponibles se identificaron automáticamente y se procesaron con la función anterior. Posteriormente, las tablas correspondientes a cada episodio se unieron en una sola base de datos.

```
archivos.srt <-  list.files(path = here::here("data", "SubtitulosProcesados"), pattern = "\\.srt$", full.names = TRUE)
subtitulos.consolidados <- data.frame()
for (ruta in archivos.srt) {
  datos.archivo <- leer.subtitulos(ruta)
  subtitulos.consolidados <- rbind(subtitulos.consolidados, datos.archivo)
}
```

3 Revisión y limpieza de los datos

Se revisó la base consolidada para identificar valores faltantes, campos vacíos y registros duplicados.

```r
colSums(is.na(subtitulos.consolidados))
```

```
    serie temporada  episodio    bloque    inicio       fin personaje     texto
        0         0         0         0         0         0         3         0
  archivo
        0
```

```r
colSums(subtitulos.consolidados == "")
```

```
    serie temporada  episodio    bloque    inicio       fin personaje     texto
        0         0         0         0         0         0        NA         0
  archivo
        0
```

```r
sum(duplicated(subtitulos.consolidados))
```

```
[1] 0
```

4 Variables de la base

La base final contiene ocho variables:

- `serie`: nombre de la serie.
- `temporada`: número de temporada.
- `episodio`: número de episodio.
- `bloque`: número del bloque de subtítulo.
- `inicio`: tiempo de inicio del subtítulo.
- `fin`: tiempo de finalización del subtítulo.
- `texto`: contenido textual del subtítulo.
- `archivo`: archivo `.srt` de origen.

5 Base de datos consolidada

A continuación se presentan las primeras 10 observaciones de la base de datos consolidada.

```r
tabla.final <- head(subtitulos.consolidados, 10)

tinytable::tt(
  tabla.final,
  caption = "Primeras 10 filas de la base de subtítulos consolidada",
  theme = "striped",
  escape = TRUE,
  width = 0.95
) |>
  tinytable::style_tt(
    fontsize = 0.8
  )
```

Table 1: Primeras 10 filas de la base de subtítulos consolidada

serie	temporada	episodio	bloque	inicio	fin	personaje	texto	archivo
The Big Bang Theory	1	2	1	00:00:02,958	00:00:05,169	Leonard	Aquí tienes. Comida tailandesa sin maní.	The Big Bang Theory S01E02 The Big Bran Hypothesis (1080p x265 10bit Joy).es(1).arreglado.srt
The Big Bang Theory	1	2	2	00:00:05,336	00:00:06,587	Howard	? Y tiene aceite de maní?	The Big Bang Theory S01E02 The Big Bran Hypothesis (1080p x265 10bit Joy).es(1).arreglado.srt
The Big Bang Theory	1	2	3	00:00:06,754	00:00:07,797	Leonard	No lo sé.	The Big Bang Theory S01E02 The Big Bran Hypothesis (1080p x265 10bit Joy).es(1).arreglado.srt
The Big Bang Theory	1	2	4	00:00:07,963	00:00:11,926	Leonard	Todos vigilen a Howard por si se inflama.	The Big Bang Theory S01E02 The Big Bran Hypothesis (1080p x265 10bit Joy).es(1).arreglado.srt
The Big Bang Theory	1	2	5	00:00:12,093	00:00:15,262	Sheldon	No hay abejas ahora, así que toma mi epinefrina.	The Big Bang Theory S01E02 The Big Bran Hypothesis (1080p x265 10bit Joy).es(1).arreglado.srt
The Big Bang Theory	1	2	6	00:00:15,805	00:00:18,516	Raj	?No tienen palitos?	The Big Bang Theory S01E02 The Big Bran